CCFBS

RAPPORT DE

Stockage et structuration des données de ventes Superstore avec PostgreSQL et SQLAlchemy

LAILA BAHIJ

02/03/2026

SOMMAIRE

1 CONTEXTE DU PROJET

2 OBJECTIF DU PROJET

3 USER STORIES

4 ÉTAPES PRINCIPALES DU PROJET

5 EXPLICATIONS SUR LA NORMALISATION ET LE CHARGEMENT DES DONNÉES

6 CONCLUTION

CONTEXTE DU PROJET

Après avoir nettoyé et préparé un dataset fiable (superstore_clean.csv), l'entreprise souhaite désormais structurer et centraliser les données dans une base relationnelle PostgreSQL.

Les raisons principales sont :

- Gérer des volumes de données croissants
- Garantir l'intégrité et la cohérence des données
- Permettre des requêtes SQL performantes
- Préparer la construction d'un dashboard interactif

L'équipe Data doit donc :

- Concevoir un modèle relationnel cohérent
- Normaliser les données
- Créer les tables dans PostgreSQL
- Charger les données via SQLAlchemy
- Vérifier l'intégrité des relations

Ce sprint introduit la logique Data Engineering de base : modélisation → création des tables → chargement → requêtes SQL.

OBJECTIF DU PROJET

OBJECTIF DU PROJET

- Concevoir un schéma relationnel normalisé
- Séparer les entités : Orders, Customers, Products, Categories, Regions
- Créer les tables avec clés primaires et clés étrangères
- Charger les données nettoyées dans PostgreSQL
- Écrire des requêtes SQL simples (SELECT, WHERE, GROUP BY, ORDER BY)
- Vérifier la cohérence et l'intégrité des données
- Suivre l'avancement via Jira

USER STORIES

3.1 Direction IT / Data

« En tant que responsable Data, je veux une base bien structurée et normalisée afin de garantir la qualité des données et faciliter les futures analyses. »

Attentes :

- Modèle relationnel clair
- Clés primaires et étrangères correctes
- Pas de redondance inutile
- Intégrité référentielle respectée

3.2 Analyste Business

« En tant qu'analyste métier, je veux pouvoir interroger facilement la base pour obtenir des indicateurs par produit, région et client. »

Exemples de requêtes attendues :

- Ventes totales par catégorie
- Profit par région
- Top clients par chiffre d'affaires
- Nombre de commandes par mois

ÉTAPES PRINCIPALES DU PROJET

Étape 1 : Création de la base et connexion

- **Créer la base PostgreSQL : superstore_db**
- **Connexion Python → PostgreSQL via SQLAlchemy**

Étape 2 : Conception du modèle relationnel

- **Identification des entités : Orders, Customers, Products, Categories, Regions**
- **Définition des primary keys et foreign keys**
- **Application de la normalisation : 1NF → 2NF → 3NF**

Étape 3 : Chargement des données

- **Séparation du CSV selon les tables normalisées**
- **Insertion des données via SQLAlchemy**
- **Vérification de l'intégrité et de la cohérence**

Étape 4 : Transformations complémentaires

- **Calcul de métriques directement dans la base :**
  - **Total Sales par produit, région, catégorie**
  - **Profit moyen par commande ou client**
- **Création de vues SQL pour analyses rapides**

Étape 5 : Préparation pour la visualisation

- **Vérification que toutes les données nécessaires pour le dashboard sont présentes**
- **Vérification des relations et clés pour permettre des jointures simples**

EXPLICATIONS SUR LA NORMALISATION ET LE CHARGEMENT DES DONNÉES

- **Normalisation** : permet d'éliminer les redondances et d'assurer l'intégrité.
- **1NF :** chaque colonne contient des valeurs atomiques
- **2NF :** toutes les colonnes non clés dépendent entièrement de la clé primaire
- **3NF :** pas de dépendance transitive entre colonnes non clés
- **Clés primaires / étrangères :**
- **Primary Key :** identifiant unique pour chaque table
- **Foreign Key :** relie les tables et garantit l'intégrité référentielle
- **Chargement des données :** via SQLAlchemy, méthode to_sql ou execute pour insérer les données nettoyées dans PostgreSQL

CONCLUSION

CONCLUSION

Ce projet a permis de transformer un fichier CSV nettoyé en une base de données relationnelle PostgreSQL structurée et normalisée.

La mise en place des tables, clés primaires et étrangères garantit l'intégrité et la cohérence des données.

Cette base est maintenant prête pour l'analyse SQL et la création de dashboards décisionnels.